Modelos de lenguaje con generación aumentada por recuperación y análisis espacial para la catalogación de presuntos feminicidios y la construcción de indicadores territoriales en Antioquia

(Formato Tercera Entrega Póster)

Daniel Felipe Villa Rengifo
Maestría en Ingeniería – Analítica
Facultad de Minas · Universidad Nacional de Colombia, Sede Medellín
Departamento de Ciencias de la Computación y la Decisión
dvilla@unal.edu.co

1. Motivación (Contexto / Propósito · Cómo · Qué)

- Medicina Legal registró **110** presuntos homicidios de mujeres en Antioquia en 2024; la tasa bajó de 5,4 a 3,1 por 100.000 mujeres entre 2018 y 2024.

Propósito: catalogar cada nuevo registro según el art. 104A, con evidencia de casos validados, y resumir los resultados en indicadores territoriales.

Cómo

1. Base validada — Registros oficiales y su noticia de prensa, con confiabilidad A1–F6 → **2. Recuperación** — Busca los casos validados más parecidos (RAG) → **3. Catalogación** — Un LLM propone literales del art. 104A con su evidencia; revisión humana → **4. Indicadores** — Cifras agregadas por subregión o municipio

Qué

- **Objeto:** registros de presunto feminicidio y de presunto homicidio de mujeres en los 125 municipios (9 subregiones) de Antioquia, 2015–2025.
  Unidad: subregión–año.



Figura 1. Celdas según presuntos homicidios de mujeres. Fuente: Policía Nacional.

2. Marco teórico (De referencia)

Feminicidio (art. 104A, Ley 1761 de 2015): causar la muerte a una mujer por su condición de ser mujer o por motivos de su identidad de género, o cuando concurra o anteceda alguna de estas circunstancias:

a) Relación actual o pasada (familiar, íntima, de convivencia, amistad, compañerismo o trabajo) y ciclo de violencia previo del autor
b) Instrumentalización de género o sexual; opresión y dominio sobre sus decisiones
c) Aprovechamiento de relaciones de poder
d) Generar terror o humillación a quien se considere enemigo
e) Antecedentes o indicios de violencia o amenaza del autor contra la víctima, denunciados o no
f) Incomunicación o privación de la libertad

- **Presunto:** sin decisión judicial, todo registro se trata como presunto.
- **RAG (generación aumentada por recuperación):** un modelo de lenguaje grande (LLM) responde con documentos recuperados de una base propia y cita la evidencia (Lewis et al., 2020).
- **Heterogeneidad espacial:** los factores asociados pueden pesar distinto en cada territorio de Antioquia (Sepúlveda Murillo et al., 2018).

3. Revisión sistemática de la literatura

- **Protocolo:** PRISMA 2020 (Page et al., 2021) en OpenAlex; título y resumen, 2015–2026; consulta del 2026-11-08. Preguntas de revisión (RQ):

RQ1 Lenguaje natural, LLM o RAG en textos sobre feminicidio o violencia contra las mujeres
RQ2 Modelos espaciales del feminicidio u homicidio de mujeres
RQ3 LLM o RAG para clasificar textos policiales o judiciales

3428 identificados → **619** revisados, sin duplicados (tope: 400 por RQ) → **478** para texto completo (141 excluidos) → **–** incluidos: en lectura

Hallazgos preliminares (títulos de los candidatos):

- RQ1: 9 de 130 mencionan LLM o GPT y 2 RAG; 3 tratan Colombia y ninguno Antioquia.
- RQ2: 19 de 60 estudian Brasil y 2 Colombia.
- RQ3: 146 de 288 son de textos legales o judiciales; 17 policiales y 4 de género.

Antecedentes: heterogeneidad espacial del feminicidio en Antioquia (Sepúlveda Murillo et al., 2018); LLM con RAG en casos de Brasil (Martínez de Lucena y Dorneles, 2026). **Brecha:** el cribado no muestra un catalogador según el art. 104A ni indicadores por subregión.

4. Problema

- Las fuentes oficiales miden cosas distintas:

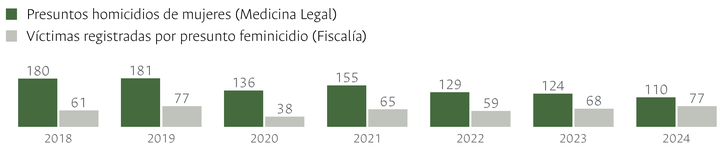


Figura 2. Antioquia, registros oficiales por año. Fuentes: Medicina Legal y Fiscalía.

- En el 62 % de los 618 registros de la Fiscalía (Antioquia, todos los años) la modalidad es «sin información» o «por establecer»; los datos abiertos consultados no indican el literal del art. 104A.
- Por municipio–año, el 89 % de las celdas tiene menos de 3 registros: las tasas municipales anuales no son estables.

Pregunta: ¿cómo catalogar de forma trazable los registros de presunto feminicidio en Antioquia según el art. 104A, y a qué nivel territorial esa catalogación produce indicadores estables?

5. Objetivos

Hipótesis: es posible catalogar los registros de presunto feminicidio en Antioquia según el art. 104A con un modelo de lenguaje que recupera casos validados, con mayor acuerdo con expertos que el mismo modelo sin recuperación, y obtener indicadores por subregión con menos ruido por azar que por municipio.

General: desarrollar un catalogador de los registros de presunto feminicidio en Antioquia según el art. 104A, con un modelo de lenguaje que recupera casos validados (RAG), que logre mayor acuerdo con expertos que el mismo modelo sin recuperación y produzca indicadores por subregión con menos ruido por azar que por municipio.

Específicos:

1. Identificar los métodos de LLM, RAG y análisis espacial usados para estudiar el feminicidio.
2. Caracterizar las fuentes de Antioquia según su confiabilidad (A1–F6) y su cobertura territorial.
3. Determinar el nivel territorial en que los indicadores tienen menos ruido por azar.
4. Construir la base de casos validados en dos versiones: interna y pública anonimizada.
5. Desarrollar el catalogador RAG que asigna los literales del art. 104A con su evidencia.
6. Evaluar el catalogador frente a expertos y frente al mismo modelo sin recuperación.

6. Diseño metodológico

Fase (objetivo)	Métodos	Producto y validación
1. Revisión (OE1)	PRISMA 2020; búsqueda reproducible en OpenAlex, luego Scopus y Web of Science	Matriz de extracción; protocolo auditable
2. Fuentes (OE2)	Inventario y clasificación A1–F6; contraste entre registros oficiales	Catálogo de fuentes
3. Nivel territorial (OE3)	Agregación municipio ⟶ subregión; ruido por azar (1/√media); modelo multinivel (municipio dentro de subregión)	Unidad de análisis justificada
4. Base de casos (OE4)	Versión interna con fuente y texto; versión pública agregada, cifras menores que 3 suprimidas	Base en dos versiones; prueba de reidentificación
5. Catalogador (OE5)	Búsqueda semántica de casos validados; LLM con salida por literal y su evidencia	Catalogador con revisión humana
6. Evaluación (OE6)	kappa de Cohen y F1 por literal frente a expertos; con y sin recuperación	Informe de evaluación; indicadores por subregión

- **Delimitaciones:** Antioquia, 2015–2025; registros ya reportados; enfoque explicativo, sin predicción.
- **Limitaciones:** rezago en la tipificación; cobertura desigual de la prensa; sin acceso a expedientes; la viabilidad se midió con todos los presuntos homicidios de mujeres, y los de presunto feminicidio son menos.
- **Cuidado de los datos:** siempre «presunto»; solo cifras agregadas, sin relatos individuales.

7. Referencias

Congreso de la República de Colombia. (2015). *Ley 1761 de 2015, por la cual se crea el tipo penal de feminicidio como delito autónomo y se dictan otras disposiciones (Rosa Elvira Cely)*. Diario Oficial 49.565. http://www.secretariasenado.gov.co/senado/basedoc/ley_1761_2015.html

Departamento Administrativo Nacional de Estadística. (s. f.). *Proyecciones de población departamental por área, sexo y edad, 2018–2050* [Conjunto de datos]. https://www.dane.gov.co/files/censo2018/proyecciones-de-poblacion/Departamental/PPED-AreaSexoEdadDep-2018-2050_VP.xlsx

Fiscalía General de la Nación. (2026). *Víctimas Fiscalía – V3* [Conjunto de datos]. Datos Abiertos Colombia. https://www.datos.gov.co/d/hr73-zqjf

Gobernación de Antioquia. (s. f.). *Cantidad anual de suicidios reportados en el Departamento de Antioquia desde 2005* [Conjunto de datos; se usa su tabla de municipios y subregiones]. Datos Abiertos Colombia. https://www.datos.gov.co/d/db67-sbus

Instituto Nacional de Medicina Legal y Ciencias Forenses. (2025). *Presuntos homicidios. Colombia, 2015 a 2024. Cifras definitivas* [Conjunto de datos]. Datos Abiertos Colombia. https://www.datos.gov.co/d/vtub-3de2

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S. y Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems, 33*, 9459–9474.

Martínez de Lucena, B. y Dorneles, C. F. (2026). Extração de informação jurídica com LLMs e RAG: um estudo sobre casos de feminicídio. En *Simpósio Brasileiro de Bancos de Dados (SBBD)* (pp. 321–327). https://doi.org/10.5753/sbbd_estendido.2026.249677

Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., Shamseer, L., Tetzlaff, J. M., Akl, E. A., Brennan, S. E., Chou, R., Glanville, J., Grimshaw, J. M., Hróbjartsson, A., Lalu, M. M., Li, T., Loder, E. W., Mayo-Wilson, E., McDonald, S., … Moher, D. (2021). The PRISMA 2020 statement: An updated guideline for reporting systematic reviews. *BMJ, 372*, n71. https://doi.org/10.1136/bmj.n71

Policía Nacional de Colombia. (s. f.). *Homicidio* [Conjunto de datos]. Datos Abiertos Colombia. https://www.datos.gov.co/d/m8fd-ahd9

Sepúlveda Murillo, F. H., Chica-Olmo, J. y Rodríguez García de Cortázar, A. (2018). The spatial heterogeneity of factors of feminicide: The case of Antioquia-Colombia. *Applied Geography, 92*, 63–73. https://doi.org/10.1016/j.apgeog.2018.01.006

Más información

Pósters, datos agregados, búsqueda de literatura y código de cada cifra.

github.com/dvillaunal/MSc-project-Fase1

Directores / Asesores

Fernán Alonso Villa Garzón, Ph.D. Tutor